

基于 VCformer 与时序模式注意力机制的排序学习选股模型——A 股市场实证分析

A Stock Ranking Model Based on VCformer and Temporal Pattern Attention:
An Empirical Study on the A-Share Market

作者信息

课程名称: 应用时间序列分析
作者邮箱: ilovemiku520@outlook.com
所在院系: 理学院
提交日期: 2026 年 7 月

目录

第一章	绪论.....	3
1.1	研究背景与意义	3
1.2	国内外研究现状	3
1.2.1	金融时序预测方法演进	3
1.2.2	深度学习在金融中的应用	4
1.2.3	排序学习与量化选股	4
1.2.4	现有框架与本文工作	4
1.3	本文的工作定位	5
第二章	相关理论与方法基础.....	7
2.1	金融时间序列的统计特征	7
2.1.1	厚尾分布与极端事件	7
2.1.2	波动率聚集与条件异方差	8
2.1.3	长记忆性与 Hurst 指数	8
2.1.4	杠杆效应与波动率不对称性	9
2.2	Transformer 架构与注意力机制	9
2.2.1	缩放点积注意力	10
2.2.2	多头注意力	10
2.2.3	位置编码	11
2.2.4	VCformer 的变量维度注意力	11
2.2.5	时序模式注意力 (TPA)	12
2.3	排序学习的数学框架	13
2.3.1	Pairwise 排序损失	13
2.3.2	排序损失与信息系数的关系	13
2.4	多任务学习框架	14
2.4.1	多任务学习的理论优势	14
2.4.2	波动率预测损失	15
2.4.3	时序分解损失	15
2.5	特征工程的理论基础	16
2.5.1	动量与反转因子	16
2.5.2	波动率因子	17

2.5.3	Amihud 非流动性	17
2.5.4	时序分解因子	17
2.5.5	动态波动率因子	18
2.6	评估理论基础	18
2.6.1	损失函数监控	19
2.6.2	预测分布分析	19
2.6.3	截面区分度检验	19
2.7	理论框架总结	20
第三章	实证分析	21
3.1	数据与实验设置	21
3.1.1	数据来源与股票池	21
3.1.2	特征工程	21
3.1.3	模型配置	22
3.1.4	训练与评估框架	22
3.2	模型训练与收敛分析	23
3.3	预测结果分析	24
3.3.1	预测覆盖与分布	24
3.3.2	排序能力评估	24
3.4	回测绩效评估	26
3.4.1	整体绩效指标	26
3.4.2	分层组合收益分析	26
3.5	模型能力与局限性讨论	27
3.5.1	排序学习的有效性与小样本陷阱	27
3.5.2	过拟合风险与数据需求	28
3.5.3	特征维度的局限与拓展方向	28
3.6	本章小结	28
附录 A	数据文件说明与实验代码	30
A.1	数据文件说明	30
A.2	代码地址及其框架结构	30
A.3	环境与依赖	31
A.4	数据获取与复现	32
附录 B	AI 使用声明	33
参考文献		33

第 1 章

绪论

1.1 研究背景与意义

金融时间序列数据（如股票价格、成交量、波动率）具有典型的高噪声、非线性和非平稳性特征，是时间序列分析领域最具挑战性的应用场景之一。传统的时间序列分析方法，如自回归移动平均（ARIMA）模型 [1]、广义自回归条件异方差（GARCH）模型 [2] 等，虽然理论基础坚实，但其线性假设难以捕捉金融数据中的复杂非线性模式。

近年来，深度学习技术的快速发展为金融时序预测提供了全新的范式。循环神经网络（RNN）、长短期记忆网络（LSTM）、Transformer 等模型在量化投资领域得到了广泛应用 [3]。然而，直接预测股票未来收益率的深度模型面临一个根本性挑战：金融时间序列的信噪比极低，有效信号往往淹没在市场噪声之中，使模型的泛化能力严重受限。

一种有效的替代思路是将选股问题转化为排序问题——不预测具体的收益率数值，而是预测股票之间的相对强弱次序。排序学习（Learning to Rank）源于信息检索领域，其核心思想是优化排序指标而非回归精度 [4]。近年来，该方法被引入量化选股，展现出优于传统回归方法的稳健性。

“时序深度学习提取特征 → 横截面排序输出策略”已成为量化选股领域的主流框架范式。ACT、RankGLU、PRISM-VQ、THU-BDC2026 等模型均遵循该范式，并在公开数据上取得了有效结果 [5–8]。本文采用 VCformer 与多尺度卷积注意力（TPA）作为时序编码器，以 Pairwise Hinge Loss 作为排序优化目标，在 A 股市场 25 只股票的数据上对该框架进行实证分析，系统考察其收敛行为与预测表现，为小样本条件下该框架的应用提供实验依据。

1.2 国内外研究现状

1.2.1 金融时序预测方法演进

金融时序预测方法经历了从线性统计模型到非线性机器学习，再到深度表征学习的演进历程。Box 和 Jenkins [1] 提出的 ARIMA 模型奠定了经典时序分析的基础。

Engle [2] 提出的 ARCH 模型及 Bollerslev [9] 推广的 GARCH 模型为波动率动态建模提供了有效工具。这些模型在平稳性假设下具有良好的统计推断性质，但难以捕捉金融数据中普遍存在的结构突变与非线性关系。

支持向量回归（SVR）和随机森林等机器学习方法通过核技巧与集成学习提升了模型的非线性拟合能力 [10]。然而，这些浅层结构仍然依赖人工设计的特征，难以自动提取多层次的时间模式，在面对高维、海量的金融数据时特征工程的瓶颈愈发突出。

1.2.2 深度学习在金融中的应用

深度学习的端到端学习范式为金融时序预测带来了新的突破。LSTM 网络因其门控机制能够捕获长程依赖，被广泛应用于股票价格预测 [11]。注意力机制的引入进一步提升了模型对关键时间步的聚焦能力，使模型能够自适应地筛选重要历史信息 [12]。

Vaswani 等 [13] 提出的 Transformer 架构通过自注意力机制实现了对任意距离依赖的直接建模，突破了循环结构的限制。在金融领域，Li 等 [14] 将 Transformer 用于股票趋势预测，发现其在捕捉长期趋势方面显著优于传统 LSTM 模型。然而，标准 Transformer 操作于时间维度，对特征变量之间的交互建模能力有限，促使研究者进一步探索变量维度注意力机制，以更充分地利用横截面因子的协同信息。

1.2.3 排序学习与量化选股

排序学习最初发轫于搜索引擎中的文档排序任务。Burgess 等 [15] 提出的 RankNet 将排序问题转化为配对分类问题，并通过梯度下降优化交叉熵损失。随后，LambdaRank [16] 引入了信息检索评价指标（如 NDCG）的梯度信息，直接优化排序质量，实现了效果的显著跃升。

在量化选股领域，排序学习的独特优势在于其直接优化股票的相对顺序，而非不可靠的绝对收益预测。Denil 等 [17] 较早将排序学习应用于股票选择。Wu 等 [18] 系统比较了多种排序损失在选股任务中的表现，发现 Pairwise Hinge Loss 在稳健性和计算效率之间取得了良好平衡，尤其适合高噪声、低信噪比的金融场景。这使得基于间隔最大化的 Pairwise 方法成为连接深度特征学习与横截面选股的重要桥梁。

1.2.4 现有框架与本文工作

近年来，多项研究遵循“时序深度学习 → 横截面排序”的统一框架，并开源了代码实现，有力推动了该方向的可复现性。代表性工作总结于表 1.1。

表 1.1: 已有“时序深度学习 → 横截面排序”框架的代表性工作

模型/研究	时序建模方式	横截面建模方式	开源代码
ACT [5]	时序分解（趋势/波动/冲击）	渐进式结构净化编码器	✓
RankGLU [6]	时序编码器	残差门控得分生成	✓
PRISM-VQ [7]	结构条件化 MoE	向量量化离散因子	✓
THU-BDC2026 [8]	TransformerEncoder	CrossStockAttention	✓
方正证券	深度网络	可微 RankIC 损失	—

上述工作表明，该框架已在多个公开数据集上被验证有效，且有可复现的代码可供参考。本文在此基础上，采用 VCformer 与 TPA 作为时序编码器，以 Pairwise Hinge Loss 为排序损失，在 A 股市场 25 只股票的数据上构建选股模型并进行实验评估，重点分析该框架在小规模数据下的收敛特性与预测表现，为在更大规模数据集上稳健应用积累实验洞见。

1.3 本文的工作定位

本文围绕“时序深度学习 → 横截面排序”框架，在 A 股市场的小规模数据集上开展系统的实证研究，具体包含以下四个方面：

- 模型构建：**采用 VCformer 与 TPA 作为时序编码器。VCformer 通过变量维度注意力机制捕获因子间的横截面交互，TPA 则利用多尺度卷积提取不同时间粒度的时序模式。二者协同构成对股票面板数据的深度表征，并最终以 Pairwise Hinge Loss 作为排序优化目标，构建完整的选股模型。
- 实证分析：**在 A 股市场 25 只股票、时间范围为 2023 年 7 月 18 日至 2026 年 7 月 17 日（约 727 个交易日）的数据上开展实验。通过记录模型训练收敛过程、损失变化趋势以及预测得分的分布特征，全面评估该框架在有限数据规模下的实际表现。
- 性能探讨：**重点观察小规模股票池条件下排序损失的下降趋势和验证集性能波动，深入剖析数据量不足时模型可能出现的过拟合现象。基于实验结果讨论模型的泛化瓶颈，为后续向大规模数据集扩展提供实证依据。
- 代码开源与可扩展性设计：**本项目的完整源代码已在 GitHub 上公开¹，旨在为金融时序量化研究提供一个可复现、可扩展的实验基准。项目代码严格遵循模块化设计原则：数据清洗、因子构建、模型训练、回测与评估等核心环节均封装为独立模块，通过统一的配置文件（config.py）集中管理所有可调参数。研究者只需修改全局变量（如 MAX_STOCKS、SEQ_LEN、BATCH_SIZE 等），即可在

¹项目地址：<https://github.com/ilovemiku520/VCStockRank>

相同代码框架下开展不同规模的实验，极大地降低了从现有研究向新场景迁移的复现成本。

为进一步验证模型在更大样本空间下的泛化能力，本项目代码支持无缝扩展至更大规模的股票池（如中证 500 或全市场选股）以及更高频率的数据（如分钟级数据）。同时，因子库（`features.py`）采用“即插即用”的设计模式：研究者只需在 `add_factors()` 方法中增加新的因子计算逻辑，或调整标准化与去极值策略，即可完成对特征空间的灵活扩展，无需改动模型结构与训练流程。这一设计使得在大样本下开展因子有效性检验、消融实验与超参数优化成为可能。

本文当前实验采用 25 只股票的小规模样本，代码框架已预留完整的数据接口与评估管线，可直接对接大规模数据源（如 Baostock 全市场数据、Wind 金融终端或本地 Parquet 文件），为后续在大样本量上的实证验证提供了坚实的技术基础。依托该代码仓库，研究者可快速复现本文结果，并根据自身研究需求定制数据范围、特征集与模型配置，便于将本文提出的技术路线扩展至更多资产类别与市场场景。

通过上述工作，本文记录了该选股框架在 A 股 25 只股票这一受限数据条件下的收敛过程与预测行为，为相关技术的复现、改进及实际部署提供了可参考的实验基线。

第 2 章

相关理论与方法基础

2.1 金融时间序列的统计特征

金融时间序列呈现出若干区别于一般时序数据的独特统计特性，这些特性构成了模型设计的重要依据。本节从概率论和随机过程的角度对这些特性进行形式化描述。

2.1.1 厚尾分布与极端事件

金融资产收益率序列的分布通常具有比正态分布更厚的尾部，即极端收益发生的概率远高于正态假设下的预期。这种“尖峰厚尾”特征意味着市场在平静中不时出现剧烈波动，其对投资组合的冲击远超传统模型所能刻画的范围。

设收益率序列 $\{r_t\}$ 的分布函数为 $F(r)$ ，其尾部分布满足：

$$\mathbb{P}(|r_t| > x) \sim Cx^{-\alpha}, \quad x \rightarrow \infty \quad (2.1.1)$$

其中 $\alpha > 0$ 为尾指数， C 为常数。 α 越小，尾部越厚。正态分布的尾部以指数速率 $\mathbb{P}(|r_t| > x) \sim e^{-x^2/2}$ 衰减，而金融数据的尾指数通常 $\alpha \in [3, 5]$ 。

从概率论角度，厚尾分布可建模为服从自由度为 ν 的 t 分布：

$$f(r) = \frac{\Gamma\left(\frac{\nu+1}{2}\right)}{\Gamma\left(\frac{\nu}{2}\right) \sqrt{\pi(\nu-2)}\sigma} \left(1 + \frac{r^2}{(\nu-2)\sigma^2}\right)^{-\frac{\nu+1}{2}} \quad (2.1.2)$$

其中 $\Gamma(\cdot)$ 为 Gamma 函数， $\nu > 2$ 为自由度参数， σ 为尺度参数。当 $\nu \rightarrow \infty$ 时， t 分布收敛于正态分布；当 ν 较小时，尾部极厚。实证研究表明，股票日收益率通常满足 $\nu \in [3, 5]$ 。

厚尾特征对模型设计的含义是：模型必须具备对异常值的稳健性，因为极端事件虽然发生概率低，但对资产组合收益的影响巨大。这一特征也说明了为什么在金融数据中不应直接使用基于正态假设的统计方法（如普通最小二乘回归），因为其估计量在厚尾分布下将丧失有效性。

2.1.2 波动率聚集与条件异方差

波动率聚集指金融时间序列中大的波动倾向于接连出现，小的波动亦然。这一现象的本质是收益率序列 $\{r_t\}$ 的条件方差 $\sigma_t^2 = \text{Var}(r_t | \mathcal{F}_{t-1})$ 具有时间依赖性，表现出时变波动率的典型特征。

Engle [2] 用 ARCH 模型描述了这一现象，其推广形式 GARCH(p, q) 为：

$$\sigma_t^2 = \alpha_0 + \sum_{i=1}^p \alpha_i \epsilon_{t-i}^2 + \sum_{j=1}^q \beta_j \sigma_{t-j}^2 \quad (2.1.3)$$

其中 $\epsilon_t = r_t - \mathbb{E}[r_t | \mathcal{F}_{t-1}]$ 为条件均值的残差项， $\alpha_0 > 0$ ， $\alpha_i \geq 0$ ， $\beta_j \geq 0$ ，且 $\sum_i \alpha_i + \sum_j \beta_j < 1$ 以保证平稳性。

GARCH 模型刻画了波动率的动态过程：当前条件方差由历史残差平方项（ ϵ_{t-i}^2 ，即过去波动的冲击）和历史条件方差项（ σ_{t-j}^2 ，即过去风险水平的持续性）共同决定。参数 α_i 刻画了波动率对市场冲击的敏感程度， β_j 刻画了波动率的持续性。该结构如同金融市场的“记忆”机制，一次冲击不仅立即抬升波动，还会在后续若干期中逐渐衰减。

波动率聚集的强度可用 $\sum_i \alpha_i + \sum_j \beta_j$ 的总和衡量。当该和接近 1 时，波动率冲击的衰减极为缓慢，此时 GARCH 过程趋近于积分型 GARCH (IGARCH)，表现出长记忆性。这一特征对风险管理和资产定价具有重要含义：波动率冲击一旦发生，将长时间影响未来风险水平，因此模型必须能够感知波动率状态的持久转变。

2.1.3 长记忆性与 Hurst 指数

长记忆性指时间序列中远距离观测值之间存在显著的相关性。具体而言，若自相关函数 $\rho(k) = \text{Corr}(r_t, r_{t-k})$ 满足：

$$\rho(k) \sim Ck^{2H-2}, \quad k \rightarrow \infty \quad (2.1.4)$$

其中 $0 < H < 1$ 为 Hurst 指数， C 为常数，则该序列具有长记忆性。当 $H \in (0.5, 1)$ 时 $\sum_{k=1}^{\infty} \rho(k)$ 发散，表明记忆无限长，历史冲击的影响会持续很久。

Hurst 指数 $H \in (0, 1)$ 的取值对应不同的时间序列行为：

- $H = 0.5$ ：无记忆性，序列近似随机游走，当前信息对未来的预测价值为零；
- $H > 0.5$ ：趋势持续性（persistence），正向自相关主导，上升趋势倾向于延续；
- $H < 0.5$ ：均值回复（mean-reversion），负向自相关主导，偏离均值后倾向于回归。

Hurst 指数的估计可通过重标极差（R/S）分析法实现。将时间序列划分为长度为 n 的连续不重叠子区间，对每个子区间计算累积离差 $X_k = \sum_{i=1}^k (r_i - \bar{r})$ ，极差

$R = \max_k X_k - \min_k X_k$ ，以及标准差 S ，进而得到重标极差 R/S 。对所有子区间取平均后记为 $(R/S)_n$ 。Hurst [19] 发现 $(R/S)_n$ 与 n 之间存在幂律关系：

$$(R/S)_n \propto n^H \quad (2.1.5)$$

因此 H 可通过 $\ln(R/S)_n$ 对 $\ln n$ 进行线性回归的斜率估计，即

$$H = \lim_{n \rightarrow \infty} \frac{\ln(R/S)_n}{\ln(n)}. \quad (2.1.6)$$

R/S 分析法的核心思想是：对于长记忆性序列，重标极差的增长速率比短记忆序列更快，呈现出超扩散行为。

对于对数收益率序列，还可利用方差-时间图进行估计：

$$\text{Var}(\ln P_t - \ln P_{t-\tau}) \propto \tau^{2H} \quad (2.1.7)$$

对 τ 与方差取对数后进行线性回归，斜率即为 $2H$ 。

Hurst 指数在选股中的含义是：高 H 的股票具有趋势跟随的交易价值，低 H 的股票更适合反转策略。本文在特征工程中构建 Hurst 指数因子，以捕捉股票价格的长记忆性特征，从记忆结构维度丰富模型的信息来源。

2.1.4 杠杆效应与波动率不对称性

杠杆效应指资产价格下跌通常伴随着未来波动率的上升，而价格上涨则伴随着波动率的下降。这一不对称性的经济解释是：公司股价下跌提高了财务杠杆（债务/权益比上升），从而增加了股票收益的波动性。此外，波动率反馈效应也指出，预期波动率上升会压低当前价格，形成负收益与高波动的联动。

这一现象可由非对称 GARCH 模型（如 GJR-GARCH[20]）描述：

$$\sigma_t^2 = \omega + \alpha \epsilon_{t-1}^2 + \beta \sigma_{t-1}^2 + \gamma \epsilon_{t-1}^2 \cdot \mathbb{I}(\epsilon_{t-1} < 0) \quad (2.1.8)$$

其中 $\mathbb{I}(\cdot)$ 为指示函数， $\gamma > 0$ 表示负冲击（ $\epsilon_{t-1} < 0$ ）对波动率的额外放大效应。

杠杆效应的强度可通过 γ 与 α 的比值衡量。当 $\gamma/\alpha > 1$ 时，负面冲击对波动率的影响显著大于正面冲击。实证研究表明，多数股票的 γ/α 在 1 至 3 之间。本文在波动率因子中引入方向性因素以刻画这一不对称性，使模型能够区分上涨与下跌状态下不同的波动模式，从而更精细地感知市场风险的结构变化。

2.2 Transformer 架构与注意力机制

Transformer 的核心是自注意力机制（Self-Attention），它通过计算序列中任意两个位置之间的相关性，实现了对长程依赖的直接建模，突破了 RNN 的递归结构对序

列长度的限制。这种全局交互能力使其天然适合捕捉金融时序中的跨期依赖关系。

2.2.1 缩放点积注意力

给定查询矩阵 $\mathbf{Q} \in \mathbb{R}^{n \times d_k}$ 、键矩阵 $\mathbf{K} \in \mathbb{R}^{m \times d_k}$ 和值矩阵 $\mathbf{V} \in \mathbb{R}^{m \times d_v}$ ，缩放点积注意力的定义为：

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^\top}{\sqrt{d_k}}\right) \mathbf{V} \quad (2.2.1)$$

其中 d_k 是键向量的维度。

该公式具有清晰的物理含义，可视为一种“软检索”机制：

1. $\mathbf{Q}\mathbf{K}^\top \in \mathbb{R}^{n \times m}$ 是相似度矩阵，其元素 $(\mathbf{Q}\mathbf{K}^\top)_{ij} = \mathbf{q}_i^\top \mathbf{k}_j$ 衡量了第 i 个查询向量与第 j 个键向量之间的内积相似度；
2. 缩放因子 $\sqrt{d_k}$ 用于防止当 d_k 较大时内积过大，导致 softmax 梯度进入饱和区（即 softmax 输出接近 one-hot 分布，梯度接近于零）；
3. softmax 将相似度转化为注意力权重 $\alpha_{ij} \geq 0$ ，满足 $\sum_j \alpha_{ij} = 1$ ，实现了对每个查询位置的归一化关注；
4. $\text{softmax}(\mathbf{Q}\mathbf{K}^\top / \sqrt{d_k})\mathbf{V}$ 对值向量按注意力权重加权求和，输出与查询位置一一对应的上下文向量。

这一过程如同查询向量在键值数据库中检索最相关的信息，然后返回加权平均后的值，从而使每个位置都能灵活聚合全局信息。

2.2.2 多头注意力

多头注意力将多个独立的注意力头拼接，使模型能够从不同的子空间捕捉多种依赖模式：

$$\text{MultiHead}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Concat}(\text{head}_1, \dots, \text{head}_h) \mathbf{W}^O \quad (2.2.2)$$

其中每个头为：

$$\text{head}_i = \text{Attention}(\mathbf{Q}\mathbf{W}_i^Q, \mathbf{K}\mathbf{W}_i^K, \mathbf{V}\mathbf{W}_i^V) \quad (2.2.3)$$

投影矩阵 $\mathbf{W}_i^Q \in \mathbb{R}^{d_{\text{model}} \times d_k}$ ， $\mathbf{W}_i^K \in \mathbb{R}^{d_{\text{model}} \times d_k}$ ， $\mathbf{W}_i^V \in \mathbb{R}^{d_{\text{model}} \times d_v}$ 将输入投影到不同的子空间。

多头注意力的设计动机是：单头注意力只能捕获一种依赖模式（例如只能关注短期反转或者只能关注长期趋势），而多头注意力通过 h 个独立头并行计算，每个头可以在不同的子空间中学习不同的依赖关系。在金融时序中，不同的头可以分别关注短期反转（ $t-1$ 到 $t-5$ 天）、中期动量（ $t-10$ 到 $t-20$ 天）和长期趋势（ $t-30$ 到 $t-60$ 天），从而实现多周期特征的并行提取，极大地提升了模型对市场结构的表达能力。

2.2.3 位置编码

由于自注意力机制本身不具有时序敏感性，对输入序列的任意排列虽然会改变 $\mathbf{QK}^\top$ ，但模型无法感知这种排列所反映的真实时序顺序，因此需要位置编码来注入时序信息。

本文采用 Vaswani 等 [13] 提出的正弦-余弦位置编码：

$$\text{PE}_{(pos, 2i)} = \sin\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right) \quad (2.2.4)$$

$$\text{PE}_{(pos, 2i+1)} = \cos\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right) \quad (2.2.5)$$

其中 pos 为时间步索引 ($0 \leq pos < T$)， i 为维度索引 ($0 \leq i < d_{\text{model}}/2$)。

该编码方式的设计原理是：

1. 不同频率的正弦/余弦波为每个位置提供唯一的编码向量；
2. 对于任意位置 pos 和偏移量 k ， PE_{pos+k} 可以表示为 PE_{pos} 的线性变换，这一性质使模型能够自然地处理相对位置信息；
3. 任意两个位置之间的内积是距离 $|pos_1 - pos_2|$ 的函数，具有平移不变性，有利于学习相对时序模式。

2.2.4 VCformer 的变量维度注意力

标准的 Transformer 在时间维度 T 上计算注意力：

$$\text{Attn}_{\text{time}}(\mathbf{X}) = \text{softmax}\left(\frac{\mathbf{X}\mathbf{X}^\top}{\sqrt{d_k}}\right) \mathbf{X} \quad (2.2.6)$$

其中 $\mathbf{X} \in \mathbb{R}^{T \times D}$ 。这一设计对每一时刻 t ，计算该时刻与所有其他时刻 t' 的相似度，而将不同时间步的信息聚合到当前步。

在股票排序问题中，每个时间步包含多个特征（如动量、波动率、换手率等），而横截面排序的核心目标正是建模这些特征之间的交互关系。VCformer 将注意力计算从时间维度转向变量维度：

$$\mathbf{X} \in \mathbb{R}^{T \times D} \xrightarrow{\text{permute}} \mathbf{X}' \in \mathbb{R}^{D \times T} \quad (2.2.7)$$

然后在特征维度 D 上执行注意力。此时查询、键向量的维度等于时间步长 T ，因此缩放因子取 $\sqrt{T}$ （若引入投影则为对应的投影维度）：

$$\text{Attn}_{\text{var}}(\mathbf{X}') = \text{softmax}\left(\frac{\mathbf{X}'\mathbf{X}'^\top}{\sqrt{T}}\right) \mathbf{X}' \quad (2.2.8)$$

最后再转置回 $\mathbb{R}^{T \times D}$ 。

VCformer 与标准 Transformer 的根本区别在于：标准 Transformer 在“不同时刻之间”做注意力，捕获的是时间依赖；VCformer 在“不同特征之间”做注意力，捕获的是特征依赖。这两种注意力从数学上看都是相同的 softmax 加权求和操作，唯一的区别在于操作的对象维度不同——这正是注意力机制作为通用操作的优势。将特征作为交互的基本单元，使得模型能够直接学习“动量增强时波动率如何反应”、“换手率与流动性溢价的关联”等横截面关系，从而更好地服务于排序任务。

两种注意力方式的对比可以通过以下表格说明：

表 2.1: 标准注意力与 VCformer 注意力的对比

	标准 Transformer	VCformer
注意力维度	时间 T	特征 D
捕获的关系	时间依赖	特征交互
权重矩阵尺寸	$T \times T$	$D \times D$
物理含义	各时刻间的信息流动	各特征间的协同/冗余

2.2.5 时序模式注意力（TPA）

金融序列中不仅存在特征间的交互，还包含丰富的多尺度时间模式，如短期反转、中期动量和长期趋势等。为自适应地提取这些模式，本文引入时序模式注意力（Temporal Pattern Attention, TPA）[21]。TPA 使用一维卷积神经网络（CNN）沿时间轴扫描，检测固定长度的时序形态，并利用注意力机制筛选与当前预测最相关的模式。

给定输入表示 $\mathbf{H} \in \mathbb{R}^{T \times d}$ ，TPA 采用 m 个长度为 w 的卷积核 $\mathbf{C}_j \in \mathbb{R}^{1 \times w}$ 在时间维度上进行因果卷积，得到模式矩阵 $\mathbf{M} \in \mathbb{R}^{(T-w+1) \times m}$ 。每个元素 $M_{t,j}$ 代表第 j 个滤波器在时间窗口 $[t-w+1, t]$ 内的响应。随后，评分函数计算各局部模式与当前时刻隐藏状态的注意力权重：

$$\alpha_{t,j} = \frac{\exp(\text{score}(\mathbf{M}_{t,j}, \mathbf{h}_T))}{\sum_{k=1}^m \exp(\text{score}(\mathbf{M}_{t,k}, \mathbf{h}_T))} \quad (2.2.9)$$

最终将模式加权求和得到时序上下文向量 $\mathbf{c} = \sum_{j=1}^m \alpha_{T,j} \mathbf{M}_{T,j}$ 。这种机制使模型能够聚焦于“上涨-盘整-突破”或“放量下跌-缩量筑底”等复合时序形态，而无需人工定义窗口长度或模式类型，显著增强了时序表示的表达力和灵活性。

本文将 TPA 部署于 VCformer 的变量注意力之后，先通过变量注意力学习特征间的协同交互，再利用 TPA 捕捉多尺度的时间动态。二者分别从横截面特征交互与时序模式演化两个维度提取信息，共同构成了对股票面板数据的深度表征。

2.3 排序学习的数学框架

排序学习的目标是学习一个实值打分函数 $f: \mathcal{X} \rightarrow \mathbb{R}$ ，使得对于任意查询（本文中为交易日）内的样本对 (x_i, x_j) ，若 $y_i > y_j$ （ y 为真实收益），则 $f(x_i) > f(x_j)$ 。相较于直接回归收益率，排序学习更加契合选股决策中“相对优劣”的本质。

2.3.1 Pairwise 排序损失

本文采用 Pairwise Hinge Loss，其定义为：

$$\mathcal{L}_{\text{rank}} = \frac{1}{N} \sum_{i,j} \max(0, \text{margin} - (s_i - s_j) \cdot (2 \cdot \mathbb{I}(y_i > y_j) - 1)) \quad (2.3.1)$$

其中 $s_i = f(x_i)$ ， $\text{margin} > 0$ 为间隔参数， $\mathbb{I}(\cdot)$ 为指示函数， $(2 \cdot \mathbb{I}(y_i > y_j) - 1)$ 即为符号函数 $\text{sign}(y_i - y_j)$ 。

该损失函数的几何含义是：

- 若 $y_i > y_j$ （股票 i 的真实收益更高），则期望 $s_i > s_j$ ；
- 定义 $z_{ij} = (s_i - s_j) \cdot \text{sign}(y_i - y_j)$ 。当排序正确时 $z_{ij} > 0$ ，排序错误时 $z_{ij} < 0$ ；
- 损失 $\max(0, \text{margin} - z_{ij})$ 不仅惩罚 $z_{ij} < 0$ （排序错误），而且要求正确对的得分差至少达到 margin ，从而在特征空间中构建一个“间隔带”，使排序边界更加稳健。

该损失函数与支持向量机（SVM）的间隔最大化思想同源，其数学性质包括：

1. 凸性：作为 Hinge Loss 的变体，该损失函数是凸的，保证了优化问题的可解性与收敛性；
2. 稀疏性：当 $z_{ij} \geq \text{margin}$ 时，损失为零，对应的样本对不贡献梯度——这与 SVM 的支持向量机制类似，只有排序困难或错误的样本对才驱动参数更新；
3. 稳健性：Hinge Loss 对 z_{ij} 的惩罚是线性的而非二次的，对离群点不敏感，在厚尾金融数据中表现更为稳健。

相比于 Pointwise 方法直接回归收益值，Pairwise 损失只关心相对顺序，天然契合选股排名的目标；而 Listwise 方法虽可优化整体排序指标，但计算复杂度高。Pairwise Hinge Loss 在效果与效率之间取得了良好平衡。

2.3.2 排序损失与信息系数的关系

信息系数（IC）定义为预测得分与未来收益之间的秩相关系数（Spearman 相关系数）：

$$\text{IC} = \text{corr}(\text{rank}(s), \text{rank}(y)) \quad (2.3.2)$$

IC 是衡量选股模型预测能力的核心指标，其取值范围为 $[-1, 1]$ 。IC > 0 表示模型具有一定的正向预测能力。

本文通过以下推导建立排序损失与 IC 的关系。令：

$$\Delta_{ij} = (s_i - s_j) \cdot (2 \cdot \mathbb{I}(y_i > y_j) - 1) \quad (2.3.3)$$

则 Δ_{ij} 可解释为样本对 (i, j) 的“排序正确性度量”。当 $\Delta_{ij} > 0$ 时，模型对该样本对的排序方向正确； Δ_{ij} 的大小反映了排序的置信度。

排序准确率定义为：

$$\text{Accuracy} = \frac{|\{(i, j) : \Delta_{ij} > 0\}|}{|\{(i, j)\}|} \quad (2.3.4)$$

Spearman 相关系数 ρ 与 Kendall 相关系数 τ 之间在二元正态假设下存在关系 $\rho = \sin(\frac{\pi}{2}\tau)$ [22]，当 τ 较小时可近似为 $\rho \approx \frac{3}{2}\tau$ 。而 Kendall 相关系数的定义正是：

$$\tau = \frac{|\{\text{concordant pairs}\}| - |\{\text{discordant pairs}\}|}{|\{\text{total pairs}\}|} \quad (2.3.5)$$

其中一致对（concordant pairs）是排序方向与真实收益方向一致的样本对，即 $\Delta_{ij} > 0$ 的样本对。

因此， $\text{Accuracy} = \frac{1}{2}(1 + \tau)$ ，而 τ 与 IC（Spearman 相关系数）正相关。从而最小化 Pairwise Hinge Loss——即最大化排序准确率和最小化排序错误——可间接促进 IC 的提升。

这一关系为排序学习在选股中的应用提供了坚实的理论支撑：与其直接优化 IC 这一不可微指标（因涉及排序操作），不如优化一个代理损失函数（Pairwise Hinge Loss）。该代理损失函数是凸的、可微的，且其优化结果与 IC 的提升方向一致。

2.4 多任务学习框架

本文的总体损失函数为三项损失之和：

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{rank}} + \lambda_{\text{vol}} \cdot \mathcal{L}_{\text{vol}} + \lambda_{\text{decomp}} \cdot \mathcal{L}_{\text{decomp}} \quad (2.4.1)$$

2.4.1 多任务学习的理论优势

多任务学习的有效性可从以下三个角度理解：

(1) 归纳偏置与正则化效应。在单任务学习中，模型可能过拟合到特定任务的噪声。多任务学习通过共享表示层，使模型在多个相关任务之间“折中”，减少了陷入特定任务局部最优的风险。从贝叶斯角度，多任务学习等价于对共享参数施加了耦合先验，这种先验鼓励不同任务的参数向相似的方向靠近，从而有效降低过拟合风险。

(2) **数据效率与迁移学习。**辅助任务提供了额外的监督信号，改善了样本利用率。例如，即使排序任务的标签存在噪声，波动率标签仍可传递风险结构信息。从信息论角度，辅助任务增加了训练数据中包含的互信息量，从而降低了样本复杂度，使模型在有限数据下也能学到更稳健的表示。

(3) **表示学习的质量提升。**多个任务共同驱动隐藏表示更可能捕获数据的本质结构，而非特定任务的噪声成分。在多任务学习中，一个特征维度如果仅对排序任务有用而对波动率任务无用，其权重将受到来自两个任务的共同约束，从而增强特征的泛化性和经济含义。

2.4.2 波动率预测损失

波动率预测损失定义为：

$$\mathcal{L}_{\text{vol}} = \frac{1}{N} \sum_i (\hat{\sigma}_i - \sigma_i)^2 \quad (2.4.2)$$

其中 $\hat{\sigma}_i$ 为预测波动率， σ_i 为真实已实现波动率：

$$\sigma_i = \sqrt{\frac{1}{K-1} \sum_{t=1}^K (r_{i,t} - \bar{r}_i)^2}, \quad K = 5 \quad (2.4.3)$$

$K = 5$ 对应未来 5 个交易日的预测窗口。

波动率预测作为辅助任务的合理性体现在：

1. 波动率与收益排序任务存在内在关联。根据 Merton [23] 的 ICAPM 框架以及 Ang 等 [24] 发现的低波动率异象，波动率本身就是收益率的横截面预测因子之一；
2. 波动率预测任务为模型提供了风险维度的监督信号，使模型学习到的表示同时包含收益信息和风险信息，这些信息的协同有助于提高排序的稳健性；
3. 在金融中，波动率的可预测性通常高于收益率的可预测性，因此波动率任务可以提供相对更可靠的梯度信号，起到辅助导航的作用。

2.4.3 时序分解损失

时序分解损失包含三项子损失：

$$\mathcal{L}_{\text{decomp}} = \mathcal{L}_{\text{smooth}} + \mathcal{L}_{\text{seasonal}} + \mathcal{L}_{\text{white}} \quad (2.4.4)$$

- (1) **趋势平滑损失。**惩罚趋势项的二阶差分，采用 ℓ_2 正则化，其思想类似于

Hodrick-Prescott 滤波:

$$\mathcal{L}_{\text{smooth}} = \sum_{t=2}^{T-1} \|\nabla^2 T_t\|^2 = \sum_{t=2}^{T-1} \|T_{t+1} - 2T_t + T_{t-1}\|^2 \quad (2.4.5)$$

该损失鼓励趋势成分的变化率本身也保持平滑,即趋势不应出现剧烈转折。这一约束符合价格趋势的金融直觉:趋势是相对缓慢变化的结构性成分,剧烈跳跃往往是噪声或事件冲击。

(2) 季节一致性损失。惩罚季节项与自身滞后周期之间的差异:

$$\mathcal{L}_{\text{seasonal}} = \sum_t \|S_t - S_{t-\text{period}}\|^2 \quad (2.4.6)$$

其中 period 参数设为 20 (约一个月交易天数)。该损失强制季节成分具有周期性,即同一相位在不同周期内的取值应当接近,对应于金融数据中的日历效应和财报季节性。

(3) 白噪声损失。惩罚残差项的自相关,采用低阶自相关系数的平方和,类似于 Ljung-Box 检验的思想:

$$\mathcal{L}_{\text{white}} = \sum_{\tau=1}^5 \left(\frac{\text{Cov}(R_t, R_{t-\tau})}{\text{Var}(R_t)} \right)^2 \quad (2.4.7)$$

该损失引导残差成分接近白噪声,即在各时间滞后的自相关趋近于零。这一约束的金融含义是:趋势和季节成分已经解释了序列中的结构化部分,残差应当是纯随机噪声,不应包含可预测的结构。

这三项损失协同引导模型将输入序列分解为具有明确物理意义的成分——趋势(缓慢变化的结构)、周期(循环波动)和噪声(不可预测的随机部分)。这种分解不仅提供了可解释的中间表示,更使得后续的排序任务能够基于更干净的信号做出决策,免受高频噪声的干扰。

2.5 特征工程的理论基础

本节阐述选取各类特征因子的理论依据,为后续的实证分析提供理论支撑。

2.5.1 动量与反转因子

动量效应 [25] 和反转效应 [26] 是金融市场中最稳健的两个异象,它们分别对应着信息的缓慢扩散和短期的过度反应。

从投资者行为角度,反转效应的产生机制是:短期价格变动主要由流动性供给和噪声交易驱动,价格偏离基本面后会向均值回归。动量效应的产生机制是:中期价格变动反映了投资者对信息的反应不足,信息在市场中缓慢扩散,导致价格持续向均衡

方向移动。

从数学上，设价格过程 P_t 满足 $P_t = P_{t-1} \exp(\mu + \epsilon_t)$ ，其中 ϵ_t 为冲击项。若冲击项具有正自相关性 $\text{Corr}(\epsilon_t, \epsilon_{t-d}) > 0$ ，则价格具有动量效应；若 $\text{Corr}(\epsilon_t, \epsilon_{t-d}) < 0$ （特别是 d 较小），则具有短期反转效应。本文选取 $d \in \{1, 5, 10, 20\}$ 以覆盖从短期反转到中期动量的不同频率，使模型能同时捕捉多种时序模式。

2.5.2 波动率因子

已实现波动率是风险的基本度量，不同期限的波动率反映不同时间尺度的风险特征：

- $d = 5$ （约 1 周）：反映短期市场情绪和突发事件的影响；
- $d = 20$ （约 1 月）：反映中期基本面不确定性和市场波动；
- $d = 60$ （约 3 月）：反映结构性风险和经济周期的影响。

在资产定价理论中，Merton [23] 的 ICAPM 表明波动率与预期收益存在正相关关系，但 Ang 等 [24] 发现低波动率股票反而有更高的风险调整后收益（低波动率异象）。这一矛盾说明波动率与收益的关系是非线性的，需要模型从数据中自适应学习，而非依赖简单的线性假设。

2.5.3 Amihud 非流动性

Amihud [27] 非流动性指标定义为：

$$\text{Amihud}_t = \frac{|r_t| \times 10^6}{V_t} \quad (2.5.1)$$

其中 V_t 为日成交量。该指标衡量了单位成交量对价格的冲击程度。其微观结构解释是：在订单簿中，一笔市场买入（卖出）订单会消耗一定深度的限价订单，导致价格向上（向下）移动。成交量越大，价格冲击越小，流动性越好。

在排序模型中，流动性因子有助于识别受流动性折价影响的股票。根据 Amihud 和 Mendelson [28] 的流动性溢价理论，流动性较差的股票需要提供更高的预期收益来补偿投资者的流动性风险，因此流动性因子是横截面收益的重要预测变量。

2.5.4 时序分解因子

STL（Seasonal-Trend Decomposition using LOESS）将价格序列分解为趋势、季节和残差：

$$P_t = T_t + S_t + R_t \quad (2.5.2)$$

STL 采用局部加权回归（LOESS）进行平滑，其优势在于季节成分可以随时间缓慢变化，比经典 X-11 分解更为灵活。

分解后构造的三个因子：

$$\text{TrendStrength}_t = \frac{|T_t|}{|P_t|}, \quad \text{SeasonalStrength}_t = \frac{\text{Std}(S_t)}{\text{Std}(P_t)}, \quad \text{ResidualStrength}_t = \frac{\text{Std}(R_t)}{\text{Std}(P_t)} \quad (2.5.3)$$

TrendStrength 衡量趋势在价格变动中的贡献度，高趋势强度的股票更可能处于稳定的趋势中，适合趋势跟随策略；**SeasonalStrength** 衡量周期成分的波动占比，高周期强度的股票可能受季节性因素驱动（如零售股在节假日的表现）；**ResidualStrength** 衡量噪声占比，高噪声的股票预测难度更大，信息提取更具挑战。

2.5.5 动态波动率因子

波动率期限结构

$$\text{VolTerm}_t = \frac{\text{RV}_{20}(t)}{\text{RV}_5(t)} \quad (2.5.4)$$

该因子反映了短期（1 周）与中期（1 月）波动率的相对关系。当 $\text{VolTerm} > 1$ 时，中期波动率高于短期波动率，表明市场预期未来波动将上升（恐慌情绪）；当 $\text{VolTerm} < 1$ 时，短期波动率高于中期波动率，表明当前波动由短期噪声驱动，市场情绪趋于稳定。

Hurst 指数

Hurst 指数 H 通过式 (2.1.6) 或 (2.1.7) 估计。其取值范围与对应的市场含义为：

- $H < 0.5$ ：序列呈现均值回复特征。在股票市场中，这可能对应受流动性冲击的股票（短期波动后价格回归）；
- $H \approx 0.5$ ：随机游走，无显著的时序结构；
- $H > 0.5$ ：序列呈现趋势特征，涨跌具有持续性。趋势跟踪策略适用于这类股票。

Hurst 指数从记忆结构维度补充了常规波动率因子的不足，将“价格行为的记忆性”这一长期特征量化为可用的因子，增强了模型对序列长期依赖的感知。

2.6 评估理论基础

本节阐述模型评估方法的设计原理和统计基础。

2.6.1 损失函数监控

训练损失与验证损失的监控是深度学习中检测过拟合的标准方法。设训练集为 $\mathcal{D}_{\text{train}}$ ，验证集为 $\mathcal{D}_{\text{val}}$ ，定义：

$$\mathcal{L}_{\text{train}}(t) = \frac{1}{|\mathcal{D}_{\text{train}}|} \sum_{(x,y) \in \mathcal{D}_{\text{train}}} \ell(f_t(x), y), \quad \mathcal{L}_{\text{val}}(t) = \frac{1}{|\mathcal{D}_{\text{val}}|} \sum_{(x,y) \in \mathcal{D}_{\text{val}}} \ell(f_t(x), y) \quad (2.6.1)$$

其中 f_t 为第 t 轮训练得到的模型。

理想情况下， $\mathcal{L}_{\text{train}}$ 和 $\mathcal{L}_{\text{val}}$ 应同时下降。当 $\mathcal{L}_{\text{train}} \downarrow$ 而 $\mathcal{L}_{\text{val}} \uparrow$ 时，表明模型对训练集的特征进行了过于精细的拟合，失去了泛化能力。在股票排序场景中，损失监控的独特价值在于：排序损失的持续下降直接反映了模型对样本对排序能力的提升，是模型有效学习最直接的证据。

2.6.2 预测分布分析

预测得分的分布特征反映了模型对横截面信息的利用程度。设第 t 日的预测得分向量为 $\mathbf{s}_t = [s_{1,t}, \dots, s_{N,t}]$ ，其横截面统计量为：

$$\begin{aligned} \mu_t &= \frac{1}{N} \sum_{i=1}^N s_{i,t}, \\ \sigma_t &= \sqrt{\frac{1}{N-1} \sum_{i=1}^N (s_{i,t} - \mu_t)^2}, \\ \gamma_{1,t} &= \frac{\frac{1}{N} \sum_{i=1}^N (s_{i,t} - \mu_t)^3}{\sigma_t^3}, \\ \gamma_{2,t} &= \frac{\frac{1}{N} \sum_{i=1}^N (s_{i,t} - \mu_t)^4}{\sigma_t^4} - 3 \end{aligned} \quad (2.6.2)$$

分别对应均值、标准差、偏度和峰度。

σ_t 越大，表明模型在横截面上的区分能力越强，能够将股票有效分散到不同的得分区间；偏度 $\gamma_{1,t}$ 反映了预测分布的不对称性（正值表示少数股票获得极高得分，可能存在局部集中看多）；峰度 $\gamma_{2,t}$ 反映了预测分布的尾部厚度（正值表示存在极端预测值，模型存在过自信风险，需警惕厚尾环境下的失效）。

2.6.3 截面区分度检验

截面区分度检验采用信息系数（IC）作为检验统计量。对于每个交易日 t ：

$$\text{IC}_t = \text{corr}_{\text{rank}}(s_{i,t}, y_{i,t+K}), \quad K = 5 \quad (2.6.3)$$

其中 $\text{corr}_{\text{rank}}$ 为 Spearman 秩相关系数， $y_{i,t+K}$ 为第 i 只股票在未来 K 日的累计收益率。

在假设 IC 序列独立同分布的条件下，其均值是否显著非零可通过 t 检验进行推断：

$$t_{IC} = \frac{\mu_{IC}}{\sigma_{IC}/\sqrt{N}}, \quad \mu_{IC} = \frac{1}{N} \sum_{t=1}^N IC_t, \quad \sigma_{IC} = \sqrt{\frac{1}{N-1} \sum_{t=1}^N (IC_t - \mu_{IC})^2} \quad (2.6.4)$$

其中 N 为交易日数。 $|t_{IC}| > 2$ 表示在 95% 置信水平下 IC 显著非零。实际应用中常采用 Newey-West 调整的标准误以处理 IC 序列可能存在的自相关，从而使推断更加稳健。

信息比率 ICIR (IC Information Ratio) 定义为：

$$ICIR = \frac{\mu_{IC}}{\sigma_{IC}} \quad (2.6.5)$$

ICIR 衡量了 IC 序列的稳定性，即模型预测能力的一致性。较高的 ICIR（通常认为 > 0.5 为可接受， > 1.0 为优秀）表明模型在不同市场状态下均表现出稳定的预测能力，而非在某些时期偶然表现良好，这是实际投资中极为看重的品质。

2.7 理论框架总结

综合以上各节，本文的理论框架可以归纳为以下逻辑链条：

- 数据特征层面：**金融时间序列的厚尾、波动率聚集、长记忆性和杠杆效应等统计特征决定了模型必须具有非线性、稳健性和对时序结构的感知能力。
- 时序建模层面：**Transformer 通过自注意力机制实现长程依赖建模；VCformer 将注意力从时间维度转向变量维度以捕获特征交互；TPA 通过多尺度卷积和注意力筛选关键时间模式，三者协同构建了对股票面板数据的深层表征。
- 学习目标层面：**排序学习将预测问题转化为相对排序问题，通过 Pairwise Hinge Loss 优化排序准确率，其优化方向与信息系数 (IC) 的最大化保持一致，为不可微的排序指标提供了可优化的代理目标。
- 多任务约束层面：**辅助任务（波动率预测、时序分解）提供额外的监督信号，引导共享表示同时蕴含收益、风险和结构信息，从而增强模型的泛化能力和解释性。
- 评估验证层面：**损失监控、预测分布分析和截面区分度检验构成多维度的评估体系，从时序和横截面两个维度全面衡量模型的预测力、稳定性和风险特征。

第 3 章

实证分析

3.1 数据与实验设置

3.1.1 数据来源与股票池

本文实验数据来源于 Baostock 开源金融数据平台，选取 A 股市场流动性较高的 25 只股票作为初始股票池，具体包括平安银行、万科 A、浦发银行等标的。数据时间范围为 2023 年 7 月 18 日至 2026 年 7 月 17 日，覆盖约 3 个自然年，共计约 727 个交易日。数据清洗流程遵循量化研究常规范式：首先剔除被特别处理（ST）的股票以避免极端事件干扰；随后对全部连续特征进行 1% 至 99% 分位点上的 Winsorize 缩尾处理，消除异常值对统计分布的影响；对缺失值采用时间序列上的前向填充与后向填充相结合的方法进行补全；最后在截面上对每一特征执行 Z-score 标准化，使得各因子在横截面上具有零均值、单位标准差的统计性质，为深度学习模型的稳定训练提供基础。

3.1.2 特征工程

本文系统性地构建了覆盖多个维度的 50 余个量价因子，形成高维特征体系。各因子类别及其代表性指标如下：

- **动量/反转因子**：捕捉不同时间窗口下的价格趋势效应与反转效应，包括 `ret_1d`, `ret_5d`, `ret_10d`, `ret_20d`。
- **波动率因子**：衡量价格波动程度，采用已实现波动率（realized volatility），覆盖 `rv_5d`, `rv_10d`, `rv_20d`, `rv_60d` 等周期。
- **流动性因子**：刻画市场交易活跃度与交易成本，包括换手率 `turnover_ratio`、Amihud 非流动性指标 `amihud` 及成交量比率 `volume_ratio`。
- **技术指标**：借鉴技术分析中常用信号，构造相对强弱指标 `rsi_14`、指数平滑异同移动平均线 `macd`、布林带相对位置 `bb_position`、平均真实波幅 `atr_14` 以及随机指标 `kdj`。

- **时序分解因子**: 应用 STL (Seasonal-Trend decomposition using LOESS) 方法对价格序列进行分解, 提取趋势强度 `trend_strength`、季节强度 `seasonal_strength` 及残差强度 `residual_strength`, 以分离不同频率成分的信息。
- **动态波动率因子**: 进一步挖掘波动率的复杂特征, 包括波动率期限结构 `vol_term_structure`、衡量长记忆性的 Hurst 指数 `hurst` 以及反映涨跌波动非对称性的 `vol_asymmetry`。

所有因子均以日频更新, 经过清洗与标准化后, 构成模型输入的原始特征张量。

3.1.3 模型配置

实验采用 VCformer + TPA (Temporal Pattern Attention) 多任务深度学习模型。VCformer 通过变量级卷积与跨变量注意力机制捕捉多变量时间序列中的复杂依赖关系, 而 TPA 模块则进一步对不同时间步的卷积特征进行注意力加权, 增强对关键时序模式的识别能力。模型关键超参数设置如表 3.1 所示。

表 3.1: 模型超参数配置

参数	取值
序列长度 (SEQ_LEN)	30 天
隐藏层维度 (HIDDEN_DIM)	64
注意力头数 (NUM_HEADS)	4
Transformer 层数 (NUM_LAYERS)	1
卷积核尺寸 (CNN_FILTERS)	[3, 6, 12, 24]
批次大小 (BATCH_SIZE)	256
学习率 (LEARNING_RATE)	5×10^{-4}
训练轮次 (EPOCHS)	20
早停耐心值 (PATIENCE)	5

基于上述超参数, 模型总体参数量约为 108 万。在仅含 25 只股票、约 6600 个有效样本的设定下, 模型复杂度明显高于数据所能提供的信息量, 存在较为严重的过参数化倾向, 这对结果的统计显著性与泛化能力构成了潜在风险, 后文将进一步讨论。

3.1.4 训练与评估框架

考虑到金融时间序列的时序依赖特性, 数据严格按时间顺序划分为训练集与测试集, 未引入未来信息。模型采用单次训练方式, 输入为每只股票过去 30 个交易日多变量时序特征张量, 预测目标为未来 5 个交易日的超额收益。排序学习任务采用 Pairwise Hinge Loss, 其数学形式为:

$$\mathcal{L}_{\text{rank}} = \max(0, m - (s_i - s_j)), \quad (3.1.1)$$

其中 s_i 与 s_j 分别为股票 i 与 j 的预测得分, m 为边际超参数。该损失鼓励模型将未来收益更高的股票赋予更高的得分。与此同时, 模型增设波动率预测辅助任务, 其损失函数采用均方误差 (MSE):

$$\mathcal{L}_{\text{vol}} = \frac{1}{N} \sum_{i=1}^N (\hat{\sigma}_i - \sigma_i)^2, \quad (3.1.2)$$

其中 $\hat{\sigma}_i$ 为预测波动率, σ_i 为真实波动率。最终多任务损失由两者加权组合构成, 即 $\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{rank}} + \lambda \mathcal{L}_{\text{vol}}$, 权重 λ 在训练中动态平衡, 以实现排序预测与风险估计的联合优化。

回测阶段采用日频调仓策略。因股票池仅含 25 只股票, 策略每日选取得分最高的全部股票构成等权组合 (即等价于等权持有整个股票池), 由此考察模型得分隐含的整体收益特征。交易成本设定为双边 0.15% 的固定费率与 0.05% 的滑点, 力求贴近真实交易环境。评估指标体系覆盖收益、风险与预测能力三个维度, 具体包括: 年化收益率、年化波动率、夏普比率、最大回撤、卡玛比率、日频胜率、盈亏比、最大连续盈利/亏损天数, 以及衡量模型排序能力的信息系数 (IC) 和信息比率 (ICIR)。

3.2 模型训练与收敛分析

模型在 20 个训练轮次内的损失函数变化情况如表 3.2 所示, 该表记录了若干代表性轮次下的总损失、排序损失、波动率损失及学习率。

表 3.2: 训练损失变化记录

Epoch	Total Loss	Rank Loss	Vol Loss	Learning Rate
1	0.1713	0.0979	0.0668	5×10^{-4}
2	0.1219	0.0955	0.0004	5×10^{-4}
5	0.1020	0.0908	0.0004	5×10^{-4}
10	0.0918	0.0860	0.0004	5×10^{-4}
15	0.0860	0.0823	0.0003	5×10^{-4}
20	0.0714	0.0648	0.0005	5×10^{-4}

从表 3.2 可以归纳出以下几点训练动态:

- 总损失快速收敛:** 初始轮次的总损失为 0.1713, 至第 20 轮已降至 0.0714, 降幅约 58%。该下降趋势表明模型在训练集上能够有效提取时序特征并逐步拟合排序信号。前两轮损失下降尤为迅速, 第 2 轮即降至 0.1219, 显示出梯度下降初期的高效率。
- 排序损失持续下降:** 排序损失由 0.0979 稳步降低至 0.0648, 虽然降幅相对平缓, 但未曾出现大幅反弹, 反映出 Pairwise Hinge Loss 优化过程的稳定性。该损失

项的持续下降意味着模型在股票相对排序上的区分能力得到逐步增强，这恰是量化选股的核心目标。

3. **波动率损失收敛极为迅速：**波动率损失在第 1 轮为 0.0668，第 2 轮即急剧收敛至 0.0004 并始终维持在该量级，说明波动率预测作为辅助任务具有极低的学习难度。该任务能够为共享表示层提供稳定的梯度信号，有助于排序任务的特征学习，而不会干扰主任务的收敛。

总体来看，训练过程中的损失曲线并未出现明显的发散或剧烈震荡，表明学习率设置、批次大小以及早停机制等超参数配置在小样本条件下具备可行性，模型的可训练性得到初步验证。

3.3 预测结果分析

3.3.1 预测覆盖与分布

模型在测试集上共产生 697 个交易日的预测得分，完整覆盖了股票池中的全部 25 只股票。预测得分的横截面统计特征如表 3.3 所示。

表 3.3: 预测得分横截面统计

统计量	数值
均值	0.0837
标准差	0.0027
最小值	0.0609
最大值	0.0860

由表可见，预测得分的均值约为 0.0837，标准差仅为 0.0027，最大值与最小值之差不足 0.026。在 25 只股票构成的有限横截面上，得分分布高度集中，表明模型赋予不同股票的得分差异极为有限，区分度受到明显约束。该现象与股票数量较少、横截面信息量不足直接相关，也预示着基于此得分的排序统计量将呈现较大的估计方差。

3.3.2 排序能力评估

信息系数（IC）是衡量预测得分与未来收益之间相关性的核心指标。在每一个交易日 t ，本文计算预测得分与次一交易日收益率在横截面上的 Pearson 相关系数，得到 IC 序列，并据此统计其均值、标准差、信息比率（ICIR）及正值比例，结果如下：

- IC 均值：0.2029
- IC 标准差：0.2447

- **ICIR** (IC 均值/IC 标准差): 0.8291
- **IC 正收益比率**: 78.19%




图 3.1

IC 均值为 0.2029，结合 78.19% 的日度正值比率，初看似乎表明预测得分与未来收益之间存在较为稳定的正向关联。然而，进一步观察信息系数的逐日时序变化（图3.1）可以更为直观地揭示其统计本质：在整个回测区间内，IC 序列基本围绕 0.2 的水平呈现无明显趋势的随机扰动，其波动幅度远大于可能存在的微弱中心趋势。这种围绕固定值上下随机波动的形态，与在零假设（真实 IC 为零）下由小样本引起的纯随机波动高度一致，意味着序列中并不存在持续、系统的预测能力。

从统计推断的角度审视，这一直观判断可得到严格支持。在横截面样本量较小的情形下，IC 估计的标准误显著放大。当零假设成立时，IC 的标准误可近似为 $1/\sqrt{N-1}$ 。本实验 $N = 25$ ，标准误约等于 $1/\sqrt{24} \approx 0.204$ 。观测到的 IC 均值 0.2029 与该标准误极为接近，对应的 t 统计量仅为 0.99，远低于常用的显著性水平临界值（如 5% 显著性水平下约为 1.96）。因此，尽管 IC 的点估计值为正，但无法拒绝“真实 IC 为零”的原假设，意味着所观察到的正向 IC 很可能仅是随机扰动在有限样本期内产生的偶然性均值偏移，模型的横截面排序能力在统计上并不显著。

此外，IC 序列的标准差为 0.2447，进一步印证了逐日波动剧烈；由此计算的信息比率 ICIR 仅为 0.8291，表明即便存在微弱信号，其稳定性也较为有限。综合 IC 时序图的随机扰动特征、均值与标准误的统计检验以及较高的波动性，可以判断：当前实验中 IC 均值偏高主要是小样本下相关系数估计方差过大的产物。在将股票池扩展至数百只后，IC 通常将回落至 0.01 至 0.05 的合理区间。

3.4 回测绩效评估

3.4.1 整体绩效指标

基于每日模型得分的等权组合在 697 个交易日（约 2.77 年）的回测区间内，获得了表 3.4 所示的核心绩效指标。

表 3.4: 回测绩效指标（25 只 A 股，2023.07–2026.07）

指标	策略表现
总收益率	236.77%
年化收益率	55.21%
年化波动率	25.66%
夏普比率	1.77
最大回撤	-18.58%
卡玛比率	2.97
日频胜率	58.76%
盈亏比	1.37
最大连续盈利	12 天
最大连续亏损	8 天

从收益维度看，策略在不足三年的时间内累计净值增长至约 3.37 倍，年化收益率达 55.21%。在风险维度，年化波动率为 25.66%，最大回撤控制在 -18.58% 之内，风险调整后收益指标——夏普比率达到 1.77，卡玛比率（年化收益率/最大回撤）为 2.97。这意味着策略在承受单位回撤风险时获得了近 3 倍的收益补偿，表现出良好的风险收益互换效率。日频胜率 58.76% 与盈亏比 1.37 的组合进一步表明，策略在多数交易日取得正收益，且平均盈利幅度高于平均亏损，具备正的期望收益特征。最大连续盈利与亏损天数分别为 12 天和 8 天，未出现极端的长周期持续回撤，策略运行相对平稳。

需要指出的是，上述绩效是 25 只特定股票在样本期内等权持有的直接结果，并不代表模型进行主动选股带来的增量收益。由于回测中每日持有的是全部股票，该绩效本质上反映的是该特定股票池在此期间的整体强劲表现，叠加了模型评分可能隐含的微弱择时或权重调整信号（如未来进一步引入不等权配置时）。因此，绩效的绝对数值不能直接外推为模型的选股能力。

3.4.2 分层组合收益分析

为进一步检验模型得分对股票横截面收益的区分能力，本文将每日股票按预测得分从低到高等分为 10 组（Group 0 为得分最低的最差组，Group 9 为得分最高的最优组），计算各分层组合在回测期内的年化收益率与夏普比率，结果如表 3.5 所示。由

于股票池仅包含 25 只股票，每组实际仅包含 2 至 3 只股票，组合的分散化程度极低，这将导致收益率出现极端放大效应。

表 3.5: 十分位组合年化收益与夏普比率

分组	年化收益率	夏普比率
Group 0（最差）	-82.96%	-4.68
Group 1	-70.40%	-3.42
Group 2	-48.22%	-2.05
Group 3	-29.56%	-0.95
Group 4	-17.54%	-0.53
Group 5	11.61%	0.51
Group 6	31.65%	0.99
Group 7	96.57%	2.42
Group 8	165.75%	3.07
Group 9（最优）	727.15%	6.19
多空组合（G9-G0）	4263.83%	9.87

表 3.5 清晰地呈现了以下特征：

- 单调性显著：**从 Group 0 至 Group 9，年化收益率严格单调递增，未出现倒挂现象。这表明模型得分与未来收益之间存在一致的正向排序关系，即使得分的绝对区分度有限，其单调性依然得到验证。
- 头尾极端分化：**最优组（Group 9）的年化收益率高达 727.15%，夏普比率达 6.19；最差组（Group 0）则年化亏损 82.96%，夏普比率为 -4.68。多空组合（做多 Group 9、做空 Group 0）的年化收益率达 4263.83%，夏普比率 9.87。造成这种极端数值的主要原因在于每组仅含 2-3 只股票，组合未能有效分散个股特异性风险，少数股票的极端收益被大幅放大。若将股票池扩展至数百只，多空组合的年化收益率通常会回落至 30%-80% 的合理区间。
- 中段组合区分度相对较弱：**Group 4 至 Group 6 之间的收益率差距相对较小，说明模型在中间评分的股票上的辨别能力仍需提升。这进一步佐证了在小样本下模型主要有效区分了极端好与极端差的股票，但对中间部分的排序能力有限。

3.5 模型能力与局限性讨论

3.5.1 排序学习的有效性与小样本陷阱

实验结果表明，Pairwise Hinge Loss 即使在有限股票池和少量样本的条件下，仍能驱动模型学习到具有单调性的排序信号。排序损失的稳定下降以及分层组合收益

的严格单调性，验证了该排序学习框架的合理性。然而，将 IC 均值置于统计检验的框架下审视时，可以明确看到，25 只股票所对应的 IC 标准误已与点估计值相当，排序能力并不显著。这与深度学习模型普遍需要大量数据才能体现优势的特性相符。当前模型参数量约为 108 万，而有效训练样本仅约 6600 个，严重过参数化使得模型极易记忆训练集中的噪声模式，从而在测试集上出现 IC 虚高和分层收益极端化的过拟合信号。

3.5.2 过拟合风险与数据需求

在如此小规模的股票池上，过拟合几乎是不可避免的。具体表现包括：IC 均值 0.20 远高于多因子模型的常规水平（0.01-0.05），Group 9 年化收益率达 727% 等脱离实际投资常识的极端数值，以及预测得分标准差极小但分层组合收益差异极大的矛盾。这一矛盾说明，模型得分微小的差异通过极低分散化的组合杠杆被急剧放大，任何偶然的排序偏差都可能产生巨大的绩效扰动。因此，当前的实证结果不具备统计意义上的稳健性，不能作为模型真实选股能力的有效证据。后续研究至少需要将股票池扩展至 50 只甚至 300 只以上，并采用滚动窗口训练与样本外测试，才能对模型性能做出可靠评估。

3.5.3 特征维度的局限与拓展方向

当前因子体系完全基于量价数据构建，未引入基本面因子（如市盈率、市净率、净资产收益率等）和宏观经济指标（如利率、采购经理人指数等）。从因子投资的理论视角看，量价因子主要捕捉市场的短期行为偏差和交易结构，而基本面与宏观因子则反映了公司的内在价值和宏观经济周期的影响，两者具有较强的信息互补性。引入多维度的异构数据不仅可以有效提升特征空间的广度，还能通过增加信息容量缓解小样本下的过拟合问题。因此，后续工作应将特征体系拓展至基本面与宏观领域，并尝试利用对抗训练、迁移学习等手段增强模型的泛化能力。

3.6 本章小结

本章在 25 只 A 股股票、697 个交易日的数据上，系统性地完成了 VCformer + TPA 多任务模型的训练、预测与回测评估。主要结论如下：

1. **可训练性验证：**模型训练过程稳定，总损失在 20 个轮次内持续下降，未出现发散或梯度消失等问题，验证了 VCformer + TPA 架构在小规模量价数据上的基本可训练性。
2. **排序框架的合理性：**分层组合收益呈现严格单调递增趋势，IC 均值为正且大部分交易日 IC 为正，初步表明排序学习框架能够从时序量价特征中提取有效的相对强弱信息。

3. **绩效表现与统计局限性：**回测组合年化收益率 55.21%，夏普比率 1.77，最大回撤 -18.58%，绩效绝对值优异。但通过 IC 标准误分析和分层组合极端值诊断，可以断定该绩效在小样本下存在严重的过拟合特征，IC 均值在统计上并不显著异于零，极端收益主要源于组合分散化不足。
4. **改进方向明确：**当前局限性——股票数量过少、特征维度局限于量价、过参数化问题以及统计显著性缺失——为后续研究提供了清晰的改进路径。扩大股票池、引入基本面与宏观因子、实施严格的滚动样本外验证，将是下一阶段工作的核心内容。

第 A 章

数据文件说明与实验代码

A.1 数据文件说明

实验过程中自动生成以下主要数据文件：

表 A.1: 数据文件说明

文件名	说明
data/factors_filled.csv	填充缺失值后的完整因子面板数据（MultiIndex: date, stock）
data/daily_raw.parquet	原始日频价格数据（未清洗，仅保留 close 列）
data/daily.parquet	清洗后的日频数据（含 OHLCV 等）
logs/best_model.pt	训练过程中验证损失最小的模型权重
backtest_returns.csv	回测每日收益序列
daily_ic.csv	每日信息系数（IC）
long_short_returns.csv	多空组合每日收益

所有数据文件均可通过运行 `main.py` 或 `backtest_main.py` 自动生成，无需额外准备。

A.2 代码地址及其框架结构

本项目的完整源代码开源于作者的 GitHub 仓库中，地址为：

<https://github.com/ilovemiku520/VCTockRank>

项目代码采用模块化设计，主要目录结构及功能说明如下：

表 A.2: 项目代码模块说明

目录/文件	功能说明
config.py	全局配置参数（股票数、序列长度、模型超参数等）
main.py	主程序入口，执行数据下载、训练、回测与评估全流程
backtest_main.py	独立回测与评估脚本，加载已训练模型进行回测
data/	数据模块
download.py	Baostock 日频数据下载
clean.py	数据清洗（去极值、缺失值填充、截面标准化）
features.py	50+ 量价因子构建
model/	模型模块
vcformer.py	VCformer 变量维度注意力实现
tpa_module.py	TPA 多尺度卷积模块
decomposition.py	时序分解模块（STL 风格）
multitask.py	多任务模型整合
training/	训练模块
dataset.py	时序数据集构建
trainer.py	训练器（早停、学习率调度、模型保存）
loss.py	多任务损失函数
portfolio/	回测模块
backtest.py	回测引擎
optimizer.py	风险平价/均值-方差组合优化
evaluation/	评估模块
factor_analysis.py	IC、分层收益、十分位组合分析
ff_regression.py	Fama-French 回归
shap_analysis.py	SHAP 模型解释
attention_vis.py	注意力权重可视化
logs/	训练日志与模型权重（自动生成）

A.3 环境与依赖

项目运行环境要求 Python 3.9 及以上，主要依赖库如下：

- PyTorch $\geq 2.0.0$
- Pandas $\geq 2.0.0$
- NumPy $\geq 1.24.0$
- SciPy $\geq 1.10.0$

- Scikit-learn $\geq 1.3.0$
- Matplotlib $\geq 3.7.0$
- Baostock $\geq 0.8.8$
- tqdm $\geq 4.65.0$

完整依赖列表见项目根目录下的 requirements.txt 文件。

A.4 数据获取与复现

1. 准备股票池文件 stock_pool.csv (包含 code 列); 2. 安装依赖: `pip install -r requirements.txt`; 3. 运行 `python main.py` 执行完整流程 (数据下载、训练、回测、评估); 4. 或运行 `python backtest_main.py` 仅执行回测与评估 (需已有训练好的模型)。

更多详细说明请参阅项目 GitHub 仓库中的 README 文档。

第 B 章

AI 使用声明

在本文的撰写与实验过程中，作者使用了以下人工智能工具进行辅助：

- **DeepSeek:** 辅助进行了文章排版与格式调整、学术文献检索与相关理论梳理；
- **OpenAI Codex:** 辅助进行了实验代码的编写、调试与优化。

所有由 AI 生成的内容均经过作者逐条审查、修改与验证，确保其准确性和学术严谨性。本文的观点、结论及可能存在的错误均由作者独立承担，与上述工具无关。

参考文献

- [1] George E. P. Box, Gwilym M. Jenkins, Gregory C. Reinsel, and Greta M. Ljung. *Time Series Analysis: Forecasting and Control*. John Wiley & Sons, 5th edition, 2015.
- [2] Robert F. Engle. Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4):987–1007, 1982.
- [3] Omer Berat Sezer, Mehmet Ugur Gudelek, and Ahmet Murat Ozbayoglu. Financial time series forecasting with deep learning : A systematic literature review: 2005–2019. *Applied Soft Computing*, 90:106181, 2020.
- [4] Christopher J. C. Burges. From RankNet to LambdaRank to LambdaMART: An overview. *Microsoft Research Technical Report MSR-TR-2010-82*, 2010.
- [5] Anonymous. Act: Adaptive component transformer for stock selection, 2025. Working Paper / Preprint.
- [6] Anonymous. Rankglu: Residual gated linear unit for stock ranking, 2025. Working Paper / Preprint.
- [7] Anonymous. Prism-vq: Structure-conditional mixture of experts with vector quantization, 2025. Working Paper / Preprint.
- [8] Anonymous. Thu-bdc2026: A stock selection model based on transformer and cross-stock attention, 2026. Working Paper / Preprint.
- [9] Tim Bollerslev. Generalized autoregressive conditional heteroskedasticity. *Journal of Econometrics*, 31(3):307–327, 1986.

- [10] Francis E. H. Tay and Lijuan Cao. Support vector machine with adaptive parameters in financial time series forecasting. *IEEE Transactions on Neural Networks*, 12(6):1430–1444, 2001.
- [11] David M. Q. Nelson, Adriano C. M. Pereira, and Renato A. de Oliveira. Stock market prediction using LSTM recurrent neural networks. *Proceedings of the International Joint Conference on Neural Networks (IJCNN)*, 2017.
- [12] Xiao Ding, Yue Zhang, Ting Liu, and Junwen Duan. A cnn-based stock price trend prediction with futures and options. *Neurocomputing*, 385:309–320, 2020.
- [13] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N. Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 5998–6008, 2017.
- [14] Qi Li, Junjie Hu, and Lingyun Wu. Temporal transformer networks for stock movement prediction. *Working Paper*, 2020.
- [15] Christopher J. C. Burges, Tal Shaked, Erin Renshaw, Ari Lazier, Matt Deeds, Nicole Hamilton, and Greg Hullender. Learning to rank using gradient descent. In *Proceedings of the 22nd International Conference on Machine Learning (ICML)*, pages 89–96, 2005.
- [16] Christopher J. C. Burges, Robert Ragno, and Quoc V. Le. Learning to rank with nonsmooth cost functions. In *Advances in Neural Information Processing Systems (NIPS)*, pages 193–200, 2006.
- [17] Misha Denil, B. Trabucco, and N. de Freitas. Learning to rank for portfolio selection. *Working Paper*, 2014.
- [18] Yue Wu, Jiajun Zhu, and Junyan Huang. Learning to rank for stock selection. *Working Paper*, 2020.
- [19] Harold Edwin Hurst. Long-term storage capacity of reservoirs. *Transactions of the American Society of Civil Engineers*, 116:770–799, 1951.
- [20] Lawrence R. Glosten, Ravi Jagannathan, and David E. Runkle. On the relation between the expected value and the volatility of the nominal excess return on stocks. *The Journal of Finance*, 48(5):1779–1801, 1993.
- [21] Shun-Yao Shih, Fan-Keng Sun, and Hung-yi Lee. Temporal pattern attention for multivariate time series forecasting. *Machine Learning*, 108:1421–1441, 2019.
- [22] Maurice G. Kendall and Jean Dickinson Gibbons. *Rank Correlation Methods*. Edward Arnold, 5th edition, 1990.
- [23] Robert C. Merton. An intertemporal capital asset pricing model. *Econometrica*, 41(5):867–887, 1973.
- [24] Andrew Ang, Robert J. Hodrick, Yuhang Xing, and Xiaoyan Zhang. The cross-section of volatility and expected returns. *The Journal of Finance*, 61(1):259–299, 2006.
- [25] Narasimhan Jegadeesh and Sheridan Titman. Returns to buying winners and selling losers: Implications for stock market efficiency. *The Journal of Finance*, 48(1):65–91, 1993.
- [26] Werner F. M. De Bondt and Richard Thaler. Does the stock market overreact? *The Journal of Finance*, 40(3):793–805, 1985.
- [27] Yakov Amihud. Illiquidity and stock returns: Cross-section and time-series effects. *Journal of Financial Markets*, 5(1):31–56, 2002.
- [28] Yakov Amihud and Haim Mendelson. Asset pricing and the bid-ask spread. *Journal of Financial Economics*, 17(2):223–249, 1986.